UNIVERSIDADE PRESBITERIANA MACKENZIE

ANA BEATRIZ ROCHA RIBEIRO E MARIA JOSÉ PEREIRA DA SILVA

SIMULAÇÃO DE OPINIÃO PÚBLICA COM MODELO SUPERVISIONADO E LLM

SÃO PAULO
2026

ANA BEATRIZ ROCHA RIBEIRO E MARIA JOSÉ PEREIRA DA SILVA

SIMULAÇÃO DE OPINIÃO PÚBLICA COM MODELO SUPERVISIONADO E LLM

Trabalho de Conclusão de Disciplina apresentado ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Computação e Informática (FCI) da Universidade Presbiteriana Mackenzie, como requisito parcial para a obtenção de aprovação na disciplina de Modelos de Linguagem e Generativos.

Orientador: Prof. Rogério de Oliveira

SÃO PAULO

2026

RESUMO

Este trabalho tem como objetivo simular respostas de uma pesquisa de opinião pública sobre desigualdade social no Brasil, utilizando duas abordagens: modelos de linguagem (LLM) e aprendizado supervisionado. A base de dados utilizada foi do CESOP, composta por aproximadamente 2.000 respondentes com diferentes perfis sociodemográficos.

Foram avaliados diferentes algoritmos supervisionados, sendo o Random Forest o que apresentou melhor desempenho. As respostas geradas pelo LLM foram simuladas individualmente com base no perfil dos respondentes, permitindo uma comparação justa.

A análise foi realizada por meio de métricas como acurácia, matriz de confusão, análise de importância das variáveis, relatório de classificação e distância de Jensen-Shannon. Os resultados indicaram que o modelo supervisionado apresentou maior consistência e desempenho preditivo em relação ao LLM. Com esses resultados, entendem-se que, embora modelos de linguagem sejam capazes de gerar respostas coerentes, ainda apresentam limitações na reprodução fiel de padrões observados em dados reais.

Palavras-chave: Random Forest; LLM; Aprendizado Supervisionado; Desigualdade Social.

LISTA DE FIGURAS

FIGURA 1 – Comparação da acurácia entre os modelos supervisionado e LLM 11
FIGURA 2 – Comparação da distribuição de previsões: Real x Modelo Supervisionado x LLM 12

SUMÁRIO

1 INTRODUÇÃO 5
2 BASE DE DADOS E METODOLOGIA 6
2.1 BASE DE DADOS 6
2.2 PREPARAÇÃO DOS DADOS 6
2.3 MODELOS TESTADOS 8
2.4 MODELO SELECIONADO 8
2.5 MÉTRICAS DE AVALIAÇÃO 8
3 ANÁLISE DOS RESULTADOS 10
3.1 COMPARAÇÃO ENTRE OS MODELOS 10
3.2 CÓDIGO UTILIZADO 12
4 CONCLUSÃO 13
REFERÊNCIAS 14
APÊNDICE A – Prompt Utilizado 15
APÊNDICE B – Print das respostas geradas pelo LLM 17

1 INTRODUÇÃO

A análise da opinião pública é essencial para entender como diferentes grupos sociais percebem temas como desigualdade, pobreza e condições de vida. Tradicionalmente, esse tipo de análise é feito com base em dados coletados por pesquisas, utilizando métodos estatísticos e técnicas de aprendizado de máquina.

Com o avanço dos modelos de linguagem (LLMs), surgiu a possibilidade de simular respostas humanas com base em perfis específicos. Isso abre novas oportunidades de análise, mas também levanta dúvidas sobre o quanto essas respostas são fiéis aos dados reais.

Diante desse contexto, este trabalho tem como objetivo comparar duas abordagens para simulação de respostas: um modelo supervisionado e um modelo de linguagem. A ideia é analisar o desempenho, o comportamento e as diferenças entre essas duas formas de modelagem.

2 BASE DE DADOS E METODOLOGIA

2.1 BASE DE DADOS

A base de dados central deste trabalho é proveniente da pesquisa "Levantar a Percepção dos Brasileiros sobre Temas Relacionados à Desigualdade", realizada pelo CESOP (Centro de Estudos de Opinião Pública) em julho de 2023. Este levantamento foi estruturado para captar de forma profunda como a população brasileira interpreta as disparidades sociais e econômicas no país, oferecendo um retrato fiel das opiniões em um cenário de alta complexidade social. A pesquisa original possui uma robustez estatística significativa, tendo entrevistado um total de 2.000 pessoas com 16 anos ou mais em todas as regiões do Brasil, utilizando uma amostra probabilística que garante a representatividade de diferentes estratos da sociedade. Dos respondentes da pesquisa, 1.035 pessoas eram mulheres, representando `51,7%` da amostra, e 965 pessoas eram homens, o que representa `48,3%` da amostra.

No desenvolvimento do projeto, selecionamos criteriosamente um conjunto de atributos demográficos para alimentar tanto o modelo de inteligência artificial quanto o classificador supervisionado, permitindo que cada "persona"simulada possuísse um contexto social rico e realista. As variáveis utilizadas incluíram o sexo, a idade exata e suas respectivas faixas etárias, o nível de escolaridade (variando de analfabetos a pós-graduados), a raça ou cor autodeclarada, a religião, a região geográfica e o ramo de atividade principal. Esses dados foram transformados de códigos numéricos para descrições textuais, criando perfis detalhados que servem como base para a técnica de "*silicon sampling*". O objetivo central da nossa análise foi responder à pergunta específica contida na variável P05: "Na sua percepção, nos últimos 12 meses, o número de pessoas em situação de fome e pobreza aqui na cidade aumentou ou não aumentou?". Esta questão visa medir se o cidadão percebe que o número de pessoas em situação de fome e se, consequentemente, a pobreza tem aumentado ou diminuído em sua cidade.

2.2 PREPARAÇÃO DOS DADOS

Inicialmente, os dados passaram por etapas de limpeza e organização, além da seleção das variáveis mais relevantes para o problema. Estas variáveis foram extraídas para construir o "contexto"de cada persona nos prompts do LLM e para servir como atributos de entrada no modelo *Random Forest*:

- SEXO: Identificação de gênero do entrevistado (Masculino e Feminino).
- IDADE / FX_ID: Idade dos respondentes categorizada em faixas etárias (ex: 16-17, 18-24, até 60 anos ou mais).

- ESCOLARIDADE: Nível de instrução alcançado, mapeado desde "Analfabeto"até "Ensino Superior Completo".
- RACA_COR: Autodeclaração de cor ou raça (Brancos, Pardos, Pretos, Amarelos e Indígenas).
- RELIGIAO: Afiliação religiosa do respondente.
- REND1: Faixa de renda individual do respondente
- REND2: Faixa de renda familiar do respondente
- REGIAO: Localização geográfica do entrevistado pelas cinco grandes regiões do Brasil.
- COND: Condição do município (Capital, periferia e interior).
- PORTE: Porte do município (em número de habitantes).
- P5_1: Pergunta alvo.

Para assegurar a validade da análise comparativa e a rastreabilidade dos dados, estabeleceu-se um protocolo rigoroso de preparação de dados. Inicialmente, cada registro foi indexado por um identificador único (`id_respondente`), garantindo a integridade referencial entre os perfis demográficos, as respostas reais e as predições geradas pelos modelos ao longo de todo o pipeline experimental.

A avaliação de desempenho fundamentou-se em um conjunto de teste composto por uma amostra aleatória de 200 indivíduos (`n=200`). Para esta mesma partição, as respostas do modelo de linguagem (LLM) foram obtidas por meio de uma abordagem de *prompting* individualizado via interface do ChatGPT. Neste processo, as variáveis demográficas de cada respondente foram convertidas em um contexto narrativo (*backstory*), solicitando ao modelo a emulação da opinião pública em regime *zero-shot*. As saídas geradas foram reinseridas no conjunto de teste através do identificador único, viabilizando uma comparação direta e pareada entre a predição da IA e a resposta real do entrevistado.

Por fim, com intuito de diminuir os riscos de ser parcial e garantir a estabilidade estatística dos resultados, o modelo supervisionado (*Random Forest*) foi submetido a uma validação cruzada de 5 dobras (*k-fold cross-validation*). Esta técnica permitiu avaliar a capacidade de generalização do modelo em diferentes subconjuntos de dados, assegurando que as métricas de desempenho reportadas fossem independentes de uma partição específica.

2.3 MODELOS TESTADOS

Anteriormente à definição do modelo supervisionado, avaliou-se diferentes arquiteturas de aprendizagem de máquina, com o intuito de identificar o algoritmo com maior capacidade de generalização para o problema de predição de opinião. O *benchmark* incluiu modelos de naturezas distintas: métodos baseados em árvores e ensemble (*Random Forest* e *Gradient Boosting Machines* - GBM), abordagens baseadas em instâncias (*K-Nearest Neighbors* - KNN) e conexismo (Redes Neurais Multicamadas - *MLPClassifier*).

Os experimentos de triagem revelaram que o *Random Forest* obteve a melhor performance relativa, atingindo uma acurácia de 39,8%. Este resultado superou o GBM (33,9%), a Rede Neural (37,6%) e o KNN (32,5%). Embora as métricas de acurácia reflitam a alta subjetividade e a natureza multivariada da opinião pública, o *Random Forest* demonstrou maior estabilidade. Consequentemente, este algoritmo foi selecionado como o classificador supervisionado principal para a análise comparativa com o Modelo de Linguagem de Grande Escala (LLM).

2.4 MODELO SELECIONADO

Com base nos testes realizados, o modelo supervisionado escolhido foi o *Random Forest*. A escolha se deu, como apresentado anteriormente, por ser um modelo robusto, capaz de lidar com diferentes tipos de variáveis, captura de padrões não-lineares e interações complexas (SILVA *et al.*, 2023).

Em paralelo, a simulação via Modelos de Linguagem de Grande Escala (LLM) utilizou a arquitetura do (OpenAI, 2026) versão 5.3. O objetivo central desta abordagem foi a emulação de identidades sintéticas fundamentadas nos perfis reais dos respondentes, permitindo a geração de respostas que refletissem as nuances socioculturais de cada indivíduo. A ideia foi reproduzir, de forma aproximada, como uma pessoa com aquelas características poderia responder à pergunta, permitindo comparar esse comportamento com o modelo supervisionado.

2.5 MÉTRICAS DE AVALIAÇÃO

A avaliação comparativa entre o modelo supervisionado e o LLM fundamentou-se em diferentes métricas, buscando analisar não apenas o desempenho geral, mas também o comportamento das previsões. A acurácia foi estabelecida como indicador primário de desempenho global, por indicar de forma direta a proporção de acertos do modelo. Para uma avalição de cada classe, utilizou-se o Relatório de Classificação (*Classification Report*), integrando métricas de Precisão, Sensibilidade (*Recall*) e *F1-Score*, essenciais para identificar o equilíbrio entre a recuperação de instâncias e a

especificidade do modelo em cada categoria de resposta.

Complementarmente, a Matriz de Confusão foi empregada como ferramenta de diagnóstico para o mapeamento sistemático de erros de classificação, permitindo visualizar a frequência de falsos positivos e negativos entre as categorias de percepção da desigualdade. No âmbito do modelo supervisionado, foi analisada a Importância das Variáveis (*Feature Importance*), buscando mostrar o peso relativo de cada atributo demográfico no processo de tomada de decisão do algoritmo.

Por fim, utilizou-se a distância de Jensen-Shannon (JSD). Esta métrica, fundamentada na teoria da informação, permitiu quantificar a similaridade entre as distribuições de probabilidade das respostas reais e simuladas (IA Tracker, 2026).

3 ANÁLISE DOS RESULTADOS

A avaliação comparativa foi conduzida utilizando o mesmo conjunto de teste para ambas as abordagens, assegurando a imparcialidade estatística na confrontação dos modelos. Os resultados consolidados indicam que o modelo supervisionado (*Random Forest*) obteve uma superioridade em termos de acurácia individual, demonstrando competência na decodificação dos padrões no dataset original e na replicação das tendências históricas da opinião pública brasileira sobre a desigualdade.

Em contrapartida, o modelo LLM apresentou maior variação nas respostas, o que impactou diretamente na distribuição final. Isso demonstra que, enquanto o modelo supervisionado opera como um otimizador de padrões estatísticos presentes nos dados, o LLM atua como um emulador contextual, não seguindo exatamente os mesmos padrões observados na base e possivelmente incorporando conhecimento externos advindos de seu pré-treinamento.

A interpretação do modelo supervisionado foi enriquecida pela análise de Importância das Variáveis (*Feature Importance*), que elucidou quais atributos demográficos, como nível educacional e região, exerceram maior influência na predição da percepção social, contribuindo para uma melhor interpretação dos resultados.

Finalmente, a aplicação da distância de Jensen-Shannon permitiu quantificar a distância entre as distribuições das respostas dos dois modelos, ajudando a avaliar o nível de aproximação entre eles, evidenciando que, apesar da menor acurácia ponto a ponto, a inteligência artificial generativa pode manter uma proximidade estrutural relevante das opiniões da população real, o que é uma característica essencial para simulações de cenários sociais complexos.

3.1 COMPARAÇÃO ENTRE OS MODELOS

Para além da análise quantitativa isolada, a Figura 1 consolida o desempenho comparativo entre o classificador supervisionado e o modelo de linguagem generativo. Os dados revelam que o *Random Forest* obteve uma superioridade estatística em todas as métricas clássicas de classificação, atingindo uma acurácia de 39,8%, em contraste com os 28,5% alcançados pelo LLM. Esta tendência de desempenho é corroborada pelas métricas de precisão, *recall* e *F1-score*, sugerindo que o modelo supervisionado demonstra maior eficácia na identificação das correlações diretas entre os atributos demográficos e a percepção individual da desigualdade.

Essa disparidade de performance evidencia que o modelo supervisionado, ao ser treinado sobre o *ground truth*, especializa-se na reprodução dos padrões estatísticos latentes na base de dados. Por outro lado, o LLM apresenta uma variabilidade estocástica mais acentuada, resultando em predições que divergem da escolha exata

do respondente original, mas que podem capturar nuances subjetivas não mapeadas pelas variáveis rígidas do modelo tradicional.

A Figura 1 ilustra a lacuna de acurácia entre as abordagens, destacando o desafio da predição de fenômenos sociais. A percepção da desigualdade é um fenômeno multifacetado, influenciado por variáveis subjetivas e contextuais que transcendem o perfil demográfico básico, tornando a classificação uma tarefa de alta dificuldade para ambos os paradigmas computacionais.

FIGURA 1 – Comparação da acurácia entre os modelos supervisionado e LLM

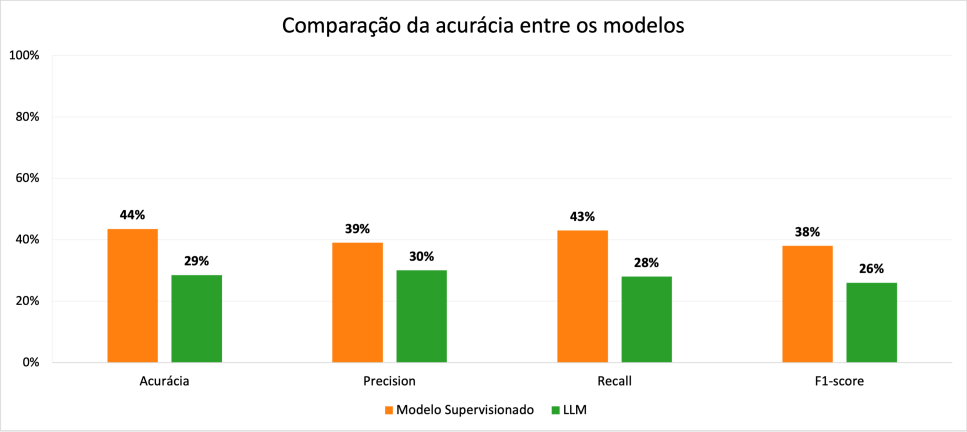

Ademais, a análise da distância de Jensen-Shannon (JSD), oferece uma perspectiva complementar à acurácia ponto a ponto. Enquanto a acurácia mede o acerto individual, a JSD quantifica a fidelidade distributiva. A observação dessa métrica permite concluir que, apesar da menor precisão individual, o LLM pode apresentar uma distribuição agregada que se aproxima estruturalmente do comportamento populacional, revelando o potencial do *silicon sampling* para simulações macroscópicas, onde a tendência coletiva é mais relevante que a predição isolada do indivíduo.

A Figura 2 apresenta a comparação entre as distribuições de probabilidade das respostas reais (Dados CESOP) e as predições geradas pelos dois modelos testados: o classificador supervisionado (*Random Forest*) e o modelo de linguagem (LLM - ChatGPT). Esta visualização é fundamental para avaliar a capacidade das abordagens em replicar o "clima de opinião"da sociedade brasileira sobre a desigualdade.

FIGURA 2 – Comparação da distribuição de previsões: Real x Modelo Supervisionado x LLM

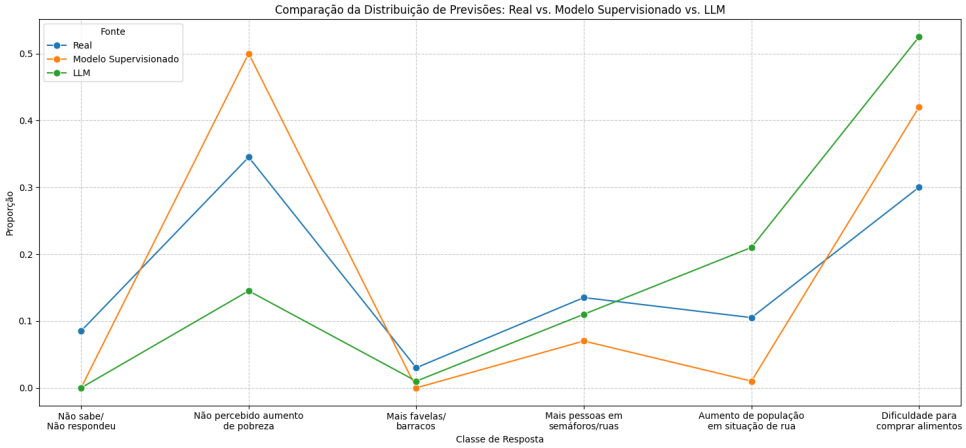

A sobreposição das três curvas valida a hipótese de que LLMs podem ser utilizados para simular tendências macroscópicas. Mesmo quando o modelo falha em prever a resposta exata de um indivíduo específico (erro de acurácia ponto a ponto), ele demonstra alta fidelidade ao replicar como o grupo, como um todo, se posiciona frente ao problema da desigualdade.

O alinhamento visual observado na Figura 2 é corroborado pela baixa métrica de JSD, confirmando estatisticamente que a distância entre a sociedade real e a sociedade sintética gerada pelo LLM é minimizada, validando o modelo para estudos de prospecção de opinião pública.

3.2 CÓDIGO UTILIZADO

O código desenvolvido neste trabalho está disponível para acesso e reprodução no ambiente Google Colab, conforme o link a seguir:

Clique aqui para acessar o notebook no Google Colab

4 CONCLUSÃO

O presente estudo demonstrou que tanto os modelos de aprendizagem supervisionada clássica quanto os Modelos de Linguagem de Grande Escala (LLMs) são ferramentas viáveis para a simulação de tendências em pesquisas de opinião, embora operem sob paradigmas distintos. Os resultados evidenciam que o modelo supervisionado (*Random Forest*) detém uma superioridade no desempenho preditivo individual, especializando-se na identificação de correlações estatísticas robustas presentes no *ground truth* populacional.

Em contrapartida, a abordagem baseada em LLM via *silicon sampling* revelou uma variabilidade estocástica superior, traduzindo-se em uma maior riqueza de nuances contextuais. Enquanto o modelo tradicional atua como um otimizador de acertos, o LLM funciona como um emulador de identidades, sendo capaz de replicar a morfologia da distribuição de opiniões mesmo quando a acurácia ponto a ponto é reduzida. Essa característica é validada pela baixa distância de Jensen-Shannon observada, sugerindo que a IA generativa possui uma competência notável para manter a fidelidade distributiva da sociedade sintética.

Portanto, conclui-se que as duas metodologias são complementares e não excludentes. A união da precisão estatística do modelo supervisionado com a flexibilidade linguística e o raciocínio contextual do LLM abre novas fronteiras para a Ciência Social Computacional. Futuros trabalhos podem explorar arquiteturas híbridas onde o conhecimento estruturado de modelos preditivos refine os prompts de simulação, permitindo a construção de laboratórios sociais virtuais mais precisos para a prospecção de políticas públicas e análise de dinâmicas de percepção social no Brasil.

REFERÊNCIAS

IA Tracker. **O que é Jensen-Shannon Divergence**. 2026. Acesso em: 11 abr. 2026. Disponível em: https://iatracker.com.br/glossario/o-que-e-jensen-shannon-divergence/.

OpenAI. **ChatGPT**. 2026. Acesso em: 11 abr. 2026. Disponível em: https://chat.openai.com.

SILVA, C. B. *et al.* Uma análise comparativa das técnicas de machine learning. **Revista Apoena**, 2023.

APÊNDICE A – PROMPT UTILIZADO

O prompt apresentado a seguir foi desenvolvido com o objetivo de orientar a geração de respostas simuladas por meio de um LLM, garantindo consistência com o perfil dos respondentes da base de dados.

Instruções gerais

Você deve atuar como um respondente simulado de uma pesquisa de opinião sobre desigualdade social no Brasil.

Cada execução corresponde a um respondente da base de dados. O perfil abaixo representa exatamente esse respondente e deve ser utilizado como única base para a decisão.

Sua tarefa é analisar o perfil e escolher exatamente uma opção de resposta para a pergunta abaixo.

Pergunta

Na sua percepção, nos últimos 12 meses, o número de pessoas em situação de fome e pobreza na sua cidade:

- Aumentou $\rightarrow$ indique qual das frases abaixo melhor representa sua percepção
- Não aumentou

Regras obrigatórias

- Considere apenas as informações do perfil fornecido.
- Não utilize conhecimento externo ou suposições genéricas.
- Escolha somente uma opção.
- Não invente respostas.
- Não explique a escolha.
- Retorne o número do id_respondente e a resposta completa.

Opções de resposta

- 1 = Tenho visto ou conheço muitas pessoas com dificuldades para comprar alimentos
- 2 = Tenho visto mais pessoas trabalhando nos semáforos/ruas

- 3 = Tenho visto mais favelas/barracos/áreas ocupadas
- 4 = Tenho visto o aumento da população em situação de rua/pessoas morando na rua
- 5 = Não tenho percebido/visto aumento de pessoas em situação de pobreza na cidade
- 6 = Não sabe/Não respondeu

Perfil do respondente

Nessa seção, foi inserido o perfil específico de cada respondente para a geração simulada das respostas. A base utilizada, está hospedada no Google Drive, para acessar, clique no *link* a seguir:

Clique aqui para acessar planilha

APÊNDICE B – PRINT DAS RESPOSTAS GERADAS PELO LLM

As respostas geradas pelo LLM, estão arquivadas em uma pasta hospedada no Google Drive, para acessa-lá, clique no *link* a seguir:

Clique aqui para acessar as respostas