Comparação entre Modelos Supervisionados e LLMs na Simulação de Respostas em Pesquisas de Opinião

Ana B. R. Ribeiro[1], **Maria J. P. da Silva**[2], **Rogério de Oliveira**[3]

[1]Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie

anabia.rochar@gmail.com, marya_medson@hotmail.com,
rogerio.oliveira@mackenzie.br

Abstract. *This study evaluates Large Language Models (LLMs) and supervised learning in the simulation of Brazilian public opinion on inequality. Using data from the CESOP-IPEC 04839 survey, with 2,000 respondents, the Silicon Sampling technique was applied to condition an LLM on specific sociodemographic profiles. Among the supervised models tested, Random Forest showed the best predictive performance. The results were evaluated using accuracy and Jensen-Shannon Distance (JSD). The findings show that, while the supervised model achieved better individual prediction performance, the LLM demonstrated greater proximity to the collective distribution of responses. This indicates that both approaches can be used in a complementary way in studies of social behavior and the simulation of hypothetical scenarios.*

Keywords: *Large Language Models, supervised learning, public opinion, Random Forest, Silicon Sampling, Jensen-Shannon.*

Resumo. *Este estudo avalia Modelos de Linguagem de Grande Porte (LLMs) e aprendizado supervisionado na simulação da opinião pública brasileira sobre desigualdade. Utilizando dados da pesquisa CESOP-IPEC 04839, com 2.000 respondentes, foi aplicada a técnica de Silicon Sampling para condicionar um LLM a perfis sociodemográficos específicos. Entre os modelos supervisionados testados, o Random Forest apresentou o melhor desempenho preditivo. A avaliação dos resultados foi realizada por meio da acurácia e da Distância de Jensen-Shannon (JSD). Os resultados mostram que, enquanto o modelo supervisionado apresentou melhor desempenho na predição individual, o LLM demonstrou maior proximidade com a distribuição coletiva das respostas. Isso indica que ambas as abordagens podem ser utilizadas de forma complementar em estudos de comportamento social e simulação de cenários hipotéticos.*

Palavras-chave: *Modelos de Linguagem de Grande Porte, aprendizado supervisionado, opinião pública, Random Forest, Silicon Sampling, Jensen-Shannon.*

1. Introdução

A análise da opinião pública é essencial para entender como diferentes grupos sociais percebem temas como desigualdade, pobreza e condições de vida. Tradicionalmente, esse

tipo de análise é feito com base em dados coletados por pesquisas, utilizando métodos estatísticos e técnicas de aprendizado de máquina.

Com o avanço dos modelos de linguagem de grande porte (LLMs), surgiu a possibilidade de simular respostas humanas com base em perfis específicos. Isso abre novas oportunidades de análise, mas também levanta dúvidas sobre o quanto essas respostas são fiéis aos dados reais.

Diante desse contexto, este trabalho tem como objetivo comparar duas abordagens para simulação de respostas: um modelo supervisionado e um modelo de linguagem. A ideia é analisar o desempenho, o comportamento e as diferenças entre essas duas formas de modelagem.

2. Metodologia

2.1. Base de Dados

A base de dados utilizada neste trabalho é proveniente da pesquisa "Levantar a Percepção dos Brasileiros sobre Temas Relacionados à Desigualdade", realizada pelo CESOP (Centro de Estudos de Opinião Pública) em julho de 2023.

A pesquisa foi desenvolvida com o objetivo de entender como a população brasileira percebe temas relacionados à desigualdade social e econômica no país. A base possui 2.000 respondentes com 16 anos ou mais, distribuídos em todas as regiões do Brasil, utilizando uma amostra probabilística com representatividade estatística.

Do total de participantes, 1.035 eram mulheres, representando `51,7%` da amostra, e 965 eram homens, correspondendo a `48,3%`.

Para o desenvolvimento do projeto, foram selecionadas variáveis demográficas utilizadas tanto no modelo supervisionado quanto no LLM, permitindo a construção de perfis individuais dos respondentes. As principais variáveis utilizadas foram sexo, idade, faixa etária, escolaridade, raça/cor, religião, região geográfica e ramo de atividade principal.

Esses dados foram convertidos de códigos numéricos para descrições textuais, facilitando a criação dos perfis utilizados na técnica de *Silicon Sampling*.

A variável alvo escolhida foi a questão P05: "Na sua percepção, nos últimos 12 meses, o número de pessoas em situação de fome e pobreza na sua cidade aumentou ou não aumentou?"

Essa pergunta foi utilizada para comparar as respostas reais da pesquisa com as previsões do modelo supervisionado e as respostas geradas pelo LLM.

2.2. Preparação dos Dados

Inicialmente, os dados passaram por etapas de limpeza, organização e seleção das variáveis mais relevantes para o problema. Essas variáveis foram utilizadas tanto para construir o contexto de cada respondente nos prompts do LLM quanto como atributos de entrada no modelo *Random Forest*:

- `SEXO`: Identificação de gênero do entrevistado (Masculino e Feminino).
- `IDADE / FX_ID`: Idade dos respondentes categorizada em faixas etárias.

- `ESCOLARIDADE`: Nível de instrução alcançado.
- `RACA_COR`: Autodeclaração de cor ou raça.
- `RELIGIAO`: Afiliação religiosa do respondente.
- `REND1`: Faixa de renda individual do respondente
- `REND2`: Faixa de renda familiar do respondente
- `REGIAO`: Localização geográfica do entrevistado pelas cinco regiões do Brasil.
- `COND`: Condição do município (Capital, periferia e interior).
- `PORTE`: Porte do município (em número de habitantes).
- `P5_1`: Pergunta alvo.

Para garantir a comparação correta entre os resultados, foi criado um identificador único chamado *id_respondente*. Esse identificador permitiu relacionar os perfis demográficos, as respostas reais da pesquisa e as previsões geradas pelos dois modelos ao longo de todo o experimento.

A metodologia de condicionamento de personas adotada neste estudo baseia-se na proposta de que LLMs podem simular respostas humanas quando recebem informações demográficas e contextuais dos indivíduos, permitindo a geração de amostras sintéticas comparáveis a pesquisas reais [Argyle et al. 2023].

A avaliação foi realizada com um conjunto de teste composto por 200 respondentes. Para esse mesmo grupo, as respostas do LLM foram geradas individualmente utilizando o ChatGPT.

Cada perfil foi transformado em um contexto narrativo *(backstory)*, contendo as informações sociodemográficas do respondente. A partir desse contexto, o modelo foi solicitado a simular uma resposta para a pergunta da pesquisa em regime *zero-shot*, ou seja, sem treinamento prévio sobre os resultados reais.

As respostas geradas foram incorporadas novamente ao conjunto de teste por meio do identificador único, permitindo a comparação direta entre a resposta real, a previsão do modelo supervisionado e a resposta gerada pelo LLM.

Por fim, para aumentar a confiabilidade dos resultados, o modelo supervisionado *Random Forest* foi submetido à validação cruzada com 5 folds (*k-fold cross-validation*). Essa técnica permitiu avaliar o desempenho do modelo em diferentes divisões da base, reduzindo a dependência de uma única separação dos dados e aumentando a estabilidade das métricas obtidas.

2.3. Modelos Testados

Antes da definição do modelo supervisionado principal, foram avaliados diferentes algoritmos de *machine learning* com o objetivo de identificar aquele com melhor desempenho para o problema de predição de opinião pública.

Foram testados modelos de diferentes abordagens, incluindo: • *Random Forest* • *Gradient Boosting Machines (GBM)* • *K-Nearest Neighbors (KNN)* • Redes Neurais Multicamadas *(MLPClassifier)*

Os resultados mostraram que o Random Forest apresentou o melhor desempenho entre os modelos avaliados, alcançando acurácia de 39,8%. Em seguida, ficaram a Rede Neural com 37,6%, o GBM com 33,9% e o KNN com 32,5%.

Mesmo com a complexidade e a subjetividade do problema, o *Random Forest* demonstrou maior estabilidade e melhor capacidade de generalização, sendo escolhido como modelo supervisionado principal para a comparação com o LLM.

2.4. Modelo Selecionado

Com base nos testes realizados, o modelo supervisionado escolhido foi o *Random Forest.* A escolha foi feita por se tratar de um modelo robusto, com bom desempenho em problemas de classificação e boa capacidade de lidar com diferentes tipos de variáveis, incluindo dados categóricos. Além disso, o algoritmo consegue capturar relações não lineares e reduzir o risco de *overfitting* por meio da combinação de múltiplas árvores de decisão [Breiman 2001, Silva et al. 2023].

Em paralelo, a abordagem com LLM utilizou o ChatGPT versão 5.3, desenvolvido pela [OpenAI 2026], como modelo de linguagem para a geração das respostas simuladas.

O objetivo dessa estratégia foi simular respostas com base nos perfis reais dos respondentes, permitindo que o modelo gerasse respostas mais próximas do comportamento humano observado na pesquisa. Cada perfil foi construído com base nas informações sociodemográficas individuais, permitindo que o LLM respondesse como se fosse aquele participante. Dessa forma, foi possível comparar diretamente o comportamento do modelo supervisionado com a resposta gerada pelo modelo de linguagem.

2.5. Métricas de Avaliação

A comparação entre o modelo supervisionado e o LLM foi realizada utilizando diferentes métricas de avaliação, buscando analisar tanto o desempenho geral quanto o comportamento das previsões.

A acurácia foi utilizada como principal medida de desempenho, pois mostra a proporção total de acertos do modelo.

Também foi utilizado o Relatório de Classificação (*Classification Report*), que apresenta as métricas de *Precision, Recall* e *F1-score*, permitindo uma análise mais detalhada do desempenho em cada classe de resposta.

A Matriz de Confusão foi empregada para identificar os principais erros de classificação, mostrando com mais clareza onde os modelos mais erram e como distribuem suas previsões.

No caso do *Random Forest*, também foi analisada a Importância das Variáveis (*Feature Importance*), com o objetivo de identificar quais características dos respondentes tiveram maior influência nas previsões.

Por fim, foi utilizada a Distância de Jensen-Shannon (JSD) para comparar as distribuições de respostas geradas pelos modelos com a distribuição real da pesquisa.

Diferente da acurácia, que avalia o acerto individual, a JSD permite medir o quanto os padrões coletivos de resposta se aproximam dos dados reais, sendo uma métrica importante para avaliar a fidelidade distributiva dos modelos [Lin 1991].

3. Análise dos Resultados

A comparação entre os modelos foi realizada utilizando o mesmo conjunto de teste para as duas abordagens, garantindo uma avaliação justa e consistente.

Os resultados mostraram que o modelo supervisionado *Random Forest* apresentou melhor desempenho na predição individual, com maior acurácia e melhores resultados nas métricas de classificação. Isso indica maior capacidade de reproduzir os padrões observados na base original da pesquisa.

Por outro lado, o modelo LLM apresentou maior variação nas respostas, o que impactou diretamente sua acurácia. Isso acontece porque o modelo de linguagem não reproduz exatamente os mesmos padrões estatísticos da base, mas sim gera respostas com base no contexto fornecido e em seu conhecimento prévio.

A análise de Importância das Variáveis ajudou a identificar quais características dos respondentes tiveram maior influência nas previsões do modelo supervisionado, como escolaridade, renda e região, contribuindo para uma melhor interpretação dos resultados.

Além disso, a Distância de Jensen-Shannon (JSD) permitiu comparar as distribuições de respostas dos modelos com a distribuição real da pesquisa. Mesmo com menor acurácia individual, o LLM apresentou boa aproximação na distribuição coletiva das respostas, mostrando potencial para simular tendências sociais em cenários mais amplos.

3.1. Comparação Entre os Modelos

A Figura 1 apresenta a comparação entre o modelo supervisionado e o LLM com base nas principais métricas de classificação.

Os resultados mostram que o *Random Forest* apresentou melhor desempenho em todas as métricas analisadas, alcançando acurácia de 39,8%, enquanto o LLM obteve 28,5%. Essa diferença também foi observada em *precision, recall* e *F1-score*, indicando que o modelo supervisionado possui maior eficiência para prever respostas individuais com base nas variáveis sociodemográficas.

Esse comportamento ocorre porque o *Random Forest* aprende diretamente com os padrões presentes nos dados reais, permitindo maior precisão nas previsões. A superioridade do modelo na predição individual reflete a eficiência do método de ensemble proposto por Breiman [Breiman 2001], que reduz o erro de generalização por meio da combinação de múltiplas árvores de decisão treinadas em subconjuntos aleatórios dos dados.

Já o LLM apresenta respostas mais variáveis, pois sua geração depende da interpretação contextual do perfil informado. Isso faz com que ele nem sempre reproduza a resposta exata do respondente, mas consiga representar padrões mais amplos de comportamento social.

A Figura 1 evidencia essa diferença entre as abordagens e mostra que a predição de opiniões sociais é uma tarefa complexa, influenciada por fatores subjetivos que nem sempre estão totalmente representados nas variáveis da base.

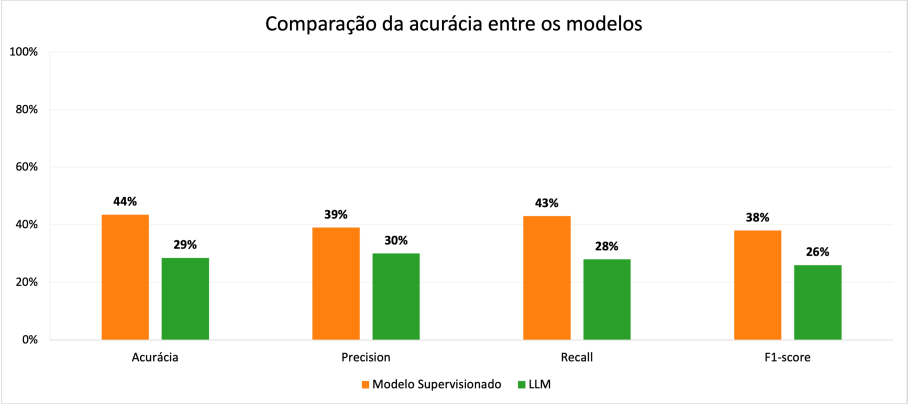

Figura 1. Comparação da acurácia entre o modelo supervisionado e LLM

Ademais, a análise da JSD complementa essa avaliação. Enquanto a acurácia mede o acerto individual, a Distância de Jensen-Shannon avalia o quanto a distribuição geral das respostas se aproxima da realidade observada na pesquisa. Nesse ponto, o LLM apresentou melhor fidelidade distributiva, mostrando maior capacidade de reproduzir o comportamento coletivo da população, mesmo com menor desempenho ponto a ponto.

A Figura 2 apresenta essa comparação entre as distribuições de respostas reais, as previsões do *Random Forest* e as respostas geradas pelo LLM.

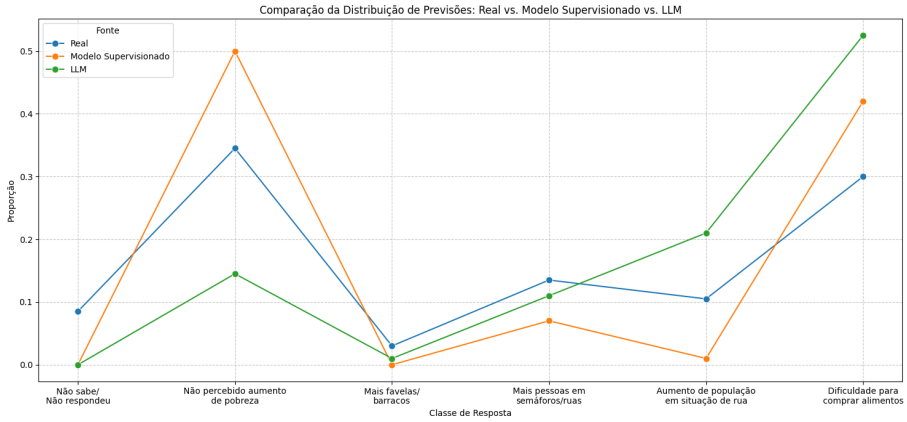

Figura 2. Comparação da distribuição de previsões: Real x Modelo Supervisionado x LLM

A proximidade visual entre as distribuições reforça a hipótese de que LLMs podem ser utilizados para simular tendências coletivas em pesquisas de opinião. Mesmo quando não acertam exatamente a resposta individual, esses modelos conseguem representar de forma consistente o comportamento geral da população.

Esse resultado é confirmado pela baixa Distância de Jensen-Shannon, mostrando que a diferença entre a distribuição real e a distribuição gerada pelo LLM permanece relativamente pequena.

3.2. Código do Projeto

Os códigos desenvolvidos, bem como os perfis sociodemográficos estruturados (formato Excel) e os registros das respostas geradas pelo LLM (formato PDF), estão disponíveis

em um repositório público[1]. A organização dos arquivos foi planejada para permitir a reprodução completa dos experimentos, incluindo os dados de entrada, os prompts utilizados, os resultados intermediários e as métricas finais. Isso garante maior transparência metodológica e facilita futuras extensões da pesquisa.

3.3. Modelo do Prompt Utilizado

O prompt detalhado a seguir, foi estruturado com base na técnica de *Persona Adoption*, com o objetivo de fazer com que o LLM assumisse o perfil de cada respondente da base. Cada prompt continha informações sociodemográficas como idade, sexo, escolaridade, renda, religião e região geográfica, permitindo que o modelo simulasse uma resposta mais próxima da realidade daquele indivíduo. Essa estratégia buscou manter consistência entre o perfil informado e a resposta gerada, reduzindo interferências externas e aumentando a qualidade da simulação.

Instruções gerais

Você deve atuar como um respondente simulado de uma pesquisa de opinião sobre desigualdade social no Brasil. Cada execução corresponde a um respondente da base de dados. O perfil abaixo representa exatamente esse respondente e deve ser utilizado como única base para a decisão. Sua tarefa é analisar o perfil e escolher exatamente uma opção de resposta para a pergunta abaixo.

Pergunta

Na sua percepção, nos últimos 12 meses, o número de pessoas em situação de fome e pobreza na sua cidade:

- Aumentou → indique qual das frases abaixo melhor representa sua percepção
- Não aumentou

Regras obrigatórias

- Considere apenas as informações do perfil fornecido.
- Não utilize conhecimento externo ou suposições genéricas.
- Escolha somente uma opção.
- Não invente respostas.
- Não explique a escolha.
- Retorne o número do id_respondente e a resposta completa.

Opções de resposta

- 1 = Tenho visto ou conheço muitas pessoas com dificuldades para comprar alimentos

[1]Ribeiro and Silva, *Comparação entre Modelo Supervisionado e LLM na Simulação de Respostas em Pesquisas de Opinião*, (2026), GitHub repository, https://github.com/Projeto-MLG/Simulacao-de-Opiniao-Publica.

- 2 = Tenho visto mais pessoas trabalhando nos semáforos/ruas
- 3 = Tenho visto mais favelas/barracos/áreas ocupadas
- 4 = Tenho visto o aumento da população em situação de rua/pessoas morando na rua
- 5 = Não tenho percebido/visto aumento de pessoas em situação de pobreza na cidade
- 6 = Não sabe/Não respondeu

Perfil do respondente

Nessa seção, foi inserido o perfil sociodemográfico estruturado utilizado para condicionar as simulações, cujos dados integrais estão disponíveis para consulta no repositório do projeto.

4. Conclusão

Este estudo mostrou que tanto os modelos supervisionados quanto os Modelos de Linguagem de Grande Porte (LLMs) podem ser utilizados para simular respostas em pesquisas de opinião pública, porém com comportamentos diferentes.

O modelo supervisionado *Random Forest* apresentou melhor desempenho preditivo individual, com maior acurácia e melhores resultados nas métricas de classificação. Isso mostra que ele possui maior capacidade de reproduzir respostas específicas com base nos padrões observados na base de dados.

Por outro lado, o LLM apresentou maior variação nas respostas, mas conseguiu manter maior proximidade com a distribuição geral da pesquisa. Isso indica que, mesmo com menor acurácia individual, ele consegue representar melhor os padrões coletivos de opinião.

A análise da Distância de Jensen-Shannon reforça esse resultado, mostrando que o LLM possui boa capacidade de simular o comportamento social agregado, enquanto o modelo supervisionado se destaca na previsão individual.

Dessa forma, conclui-se que as duas abordagens não devem ser vistas como concorrentes, mas como complementares. O uso combinado dessas técnicas pode contribuir para estudos de comportamento social, simulação de cenários hipotéticos e apoio à formulação de políticas públicas.

Referências

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., and Williams, D. Q. (2023). Out of one, many: Using language models to simulate human samples. *Political Analysis*, 31(3):337–351.

Breiman, L. (2001). Random forests. *Machine learning*, 45:5–32.

Lin, J. (1991). Divergence measures based on the shannon entropy. *IEEE Transactions on Information theory*, 37(1):145–151.

OpenAI (2026). Chatgpt. `https://chat.openai.com`. Acesso em: 11 abr. 2026.

Silva, C. B. et al. (2023). Uma análise comparativa das técnicas de machine learning. *Revista Apoena*.